

Introducción a la programación

ASCII y UNICODE

Dr. Rodrigo Vázquez López

Universidad Autónoma de la Ciudad de México
Plantel San Lorenzo Tezonco

Semestre 2025-II

UACM

Universidad Autónoma
de la Ciudad de México

NADA HUMANO ME ES AJENO

Preguntas...

¿Qué es un **character**?

¿Cuántos **caracteres** conoces? ¿De que **tipo**?

¿Cómo se representan los caracteres en la **computadora**?



Representación de caracteres

De la misma forma que utilizamos vectores binarios para representar números enteros, asociamos **caracteres alfanuméricos** a **vectores de bits**, para ello crear una **función** para **traducir** de uno a otro.



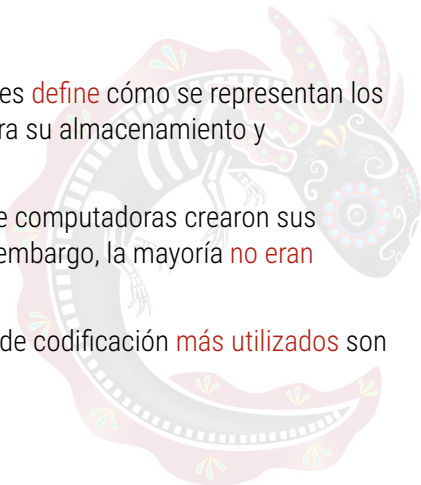
Estándares de codificación

Un **estándar de codificación** de caracteres **define** cómo se representan los **caracteres** en un sistema informático para su almacenamiento y procesamiento.

Durante mucho tiempo los **fabricantes** de computadoras crearon sus **estándares propios** de codificación, sin embargo, la mayoría **no eran compatibles** entre si.

Actualmente, algunos de los estándares de codificación **más utilizados** son los siguientes:

- **ASCII** y sus extensiones
- **UNICODE** (UTF-8, UTF-16 y UTF-32)



El código **ASCII (American Standard Code for Information Interchange)** es uno de los **estándares de codificación de caracteres** de los **más antiguos** (creado en 1967) y de los más simples, el cual:

- Se desarrolló originalmente para comunicarse entre los primeros dispositivos de **teleimpresora** y máquinas mecánicas.
- Utiliza una codificación de **7 bits** para representar un juego de **128 caracteres**
- Los primeros **32 caracteres** son de **control**, el resto son **imprimibles**.
- ASCII esta pensado y diseñado para el **idioma inglés**, por lo que no toma en cuenta la **ñ** y las **vocales acentuadas**.

Tabla de caracteres ASCII

H \ L	00	01	02	03	04	05	06	07	08	09	0A	0B	0C	0D	0E	0F
00	NUL	SOH	STX	ETX	EOT	ENQ	ACK	BEL	BS	TAB	LF	VT	FF	CR	SO	SI
10	DLE	DC1	DC2	DC3	DC4	NAK	SYN	ETB	CAN	EM	SUB	ESC	FS	GS	RS	US
20	(SPA)	!	"	#	\$	%	&	'	(	)	*	+	,	-	.	/
30	0	1	2	3	4	5	6	7	8	9	:	;	<	=	>	?
40	@	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
50	P	Q	R	S	T	U	V	W	X	Y	Z	[	\	]	^	_
60	`	a	b	c	d	e	f	g	h	i	j	k	l	m	n	o
70	p	q	r	s	t	u	v	w	x	y	z	{		}	~	



Caracteres de control



Caracteres numéricos



Alfabeto latino



Caracteres especiales

Codificación en ASCII

Podemos representar cualquier cadena de caracteres (texto) utilizando el código ASCII, para ello:

- **Separamos** todos los **caracteres** de la cadena.
- Con ayuda de la **tabla ASCII**, **buscamos** el valor en **hexadecimal** de cada carácter y los anotamos debajo de cada carácter.
- Si la cadena contiene **saltos de línea**, estos se representan con los caracteres de control **CR/LF** en **sistemas windows** o **LF** en **sistemas unix**.
- Una vez codificados la totalidad de los caracteres, **se agrega** al final un **carácter no imprimible** llamado **fin de línea** el cual se representa con el carácter **NUL** o **\0**
- El carácter **fin de línea** que sirve para **indicarle** a la computadora **donde termina** la cadena.

Codificación en ASCII

Ejemplo:

La palabra **Computadora** en ASCII se codifica de la siguiente forma:

C	o	m	p	u	t	a	d	o	r	a	\0
0x43	0x6F	0x6D	0x70	0x75	0x74	0x61	0x64	0x6F	0x72	0x61	0x00

Ejemplo:

Codifique la siguiente cadena de texto en ASCII

Hola!
Saludos.

La cadena codificada en **sistemas windows** es:

H	o	l	a	!	CR	LF	S	a	l	u	d	o	s	.	\0
0x48	0x6F	0x6C	0x61	0x21	0x0D	0x0A	0x53	0x61	0x6C	0x75	0x64	0x6F	0x73	0x2E	0x00

Ejercicios

Codifique las siguientes cadenas de caracteres utilizando ASCII:

- Introduccion a la programacion
- Constitucion de 1917
- UACM
MINAS
AV. DEL ARBOL
- Juan!
Responde!!
corre!




ASCII extendido

Se denomina **ASCII extendido** a cualquier **código de caracteres** de **8 bits**, en el cual los códigos 32 a 126 **coinciden** con los **caracteres imprimibles** de **ASCII**.

Las codificaciones de **ASCII extendido** utilizan además parte o la **totalidad** de los códigos **superiores** a 128 para codificar **caracteres adicionales** a los **caracteres imprimibles** ASCII.

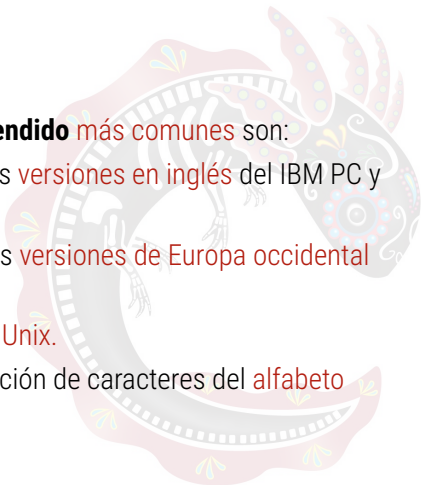
Algunos caracteres como la **letra ñ** y las **vocales acentuadas** se encuentran dentro de estos códigos



Codificaciones ASCII extendido

Algunas de las codificaciones **ASCII extendido** más comunes son:

- **Página de códigos 437**: usual en las versiones en inglés del IBM PC y MS-DOS.
- **Página de códigos 850**: usual en las versiones de Europa occidental del IBM PC y MS-DOS.
- **Latin-1 (ISO/IEC 8859-1)**: típico de Unix.
- **Windows-1252 (CP-1252)**: codificación de caracteres del alfabeto latino.



Página de códigos 437

	-0	-1	-2	-3	-4	-5	-6	-7	-8	-9	-A	-B	-C	-D	-E	-F	
0-		☉	☿	♥	♠	♣	♠	•	▣	○	♠	♂	♀	♪	♪	☀	0-
1-	▶	◀	↕			§	—	↑	↑	↓	→	←	L	↔	▲	▼	1-
2-		!	"	#	\$	%	&	'	(	)	*	+	,	-	.	/	2-
3-	0	1	2	3	4	5	6	7	8	9	:	;	<	=	>	?	3-
4-	@	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	4-
5-	P	Q	R	S	T	U	V	W	X	Y	Z	[	\	]	^	_	5-
6-	`	a	b	c	d	e	f	g	h	i	j	k	l	m	n	o	6-
7-	p	q	r	s	t	u	v	w	x	y	z	{		}	~	△	7-
8-	Ç	ü	é	â	ä	à	å	ç	ê	ë	è	ï	î	í	Ä	Å	8-
9-	É	æ	Æ	ô	ö	ò	û	ù	ý	Ö	Ü	¢	£	¥	Pts	f	9-
A-	á	í	ó	ú	ñ	Ñ	ª	º	¿	¬	¬	½	¼	¿	«	»	A-
B-	☐	☐	☐														B-
C-	L	⊥	T	⊥	+	+	+	+	+	+	+	+	+	+	+	+	C-
D-	⊥	⊥	⊥	⊥	⊥	⊥	⊥	⊥	⊥	⊥	⊥	⊥	⊥	⊥	⊥	⊥	D-
E-	α	β	Γ	π	Σ	σ	μ	τ	Φ	Θ	Ω	δ	∞	φ	ε	∩	E-
F-	≡	±	≥	≤			÷	≈	°	.	.	√	n	2	■		F-
	-0	-1	-2	-3	-4	-5	-6	-7	-8	-9	-A	-B	-C	-D	-E	-F	



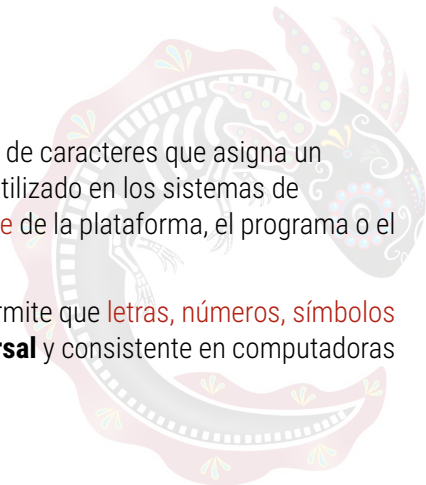
Windows-1252

8-	€ 0080 128*		¡ 201A 130*	¢ 0192 131*	£ 201E 132*	… 2026 133*	† 2020 134*	‡ 2021 135*	~ 02C6 136*	‰ 2030 137*	Š 0160 138*	‹ 2039 139*	ƒ 0152 140*		Ž 017D 142*	
9-		€ 145*	¡ 146*	¢ 147*	£ 148*	… 149*	† 150*	‡ 151*	~ 02DC 152*	‰ 2122 153*	Š 0161 154*	‹ 203A 155*	ƒ 0153 156*		Ž 017E 158*	Ÿ 0178 159*
A-	nbsp 00A0 160	í 00A1 161	í 00A2 162	£ 00A3 163	¤ 00A4 164	¥ 00A5 165	¦ 00A6 166	§ 00A7 167	¨ 00A8 168	© 00A9 169	ª 00AA 170	« 00AB 171	¬ 00AC 172	SHY 00AD 173	® 00AE 174	¯ 00AF 175
B-	° 00B0 176	± 00B1 177	² 00B2 178	³ 00B3 179	´ 00B4 180	µ 00B5 181	¶ 00B6 182	· 00B7 183	¸ 00B8 184	¹ 00B9 185	º 00BA 186	» 00BB 187	¼ 00BC 188	½ 00BD 189	¾ 00BE 190	¿ 00BF 191
C-	À 00C0 192	Á 00C1 193	Â 00C2 194	Ã 00C3 195	Ä 00C4 196	Å 00C5 197	Æ 00C6 198	Ç 00C7 199	È 00C8 200	É 00C9 201	Ê 00CA 202	Ë 00CB 203	Ì 00CC 204	Í 00CD 205	Î 00CE 206	Ï 00CF 207
D-	Ð 00D0 208	Ñ 00D1 209	Ò 00D2 210	Ó 00D3 211	Ô 00D4 212	Õ 00D5 213	Ö 00D6 214	× 00D7 215	Ø 00D8 216	Ù 00D9 217	Ú 00DA 218	Û 00DB 219	Ü 00DC 220	Ý 00DD 221	Þ 00DE 222	ß 00DF 223
E-	à 00E0 224	á 00E1 225	â 00E2 226	ã 00E3 227	ä 00E4 228	å 00E5 229	æ 00E6 230	ç 00E7 231	è 00E8 232	é 00E9 233	ê 00EA 234	ë 00EB 235	ì 00EC 236	í 00ED 237	î 00EE 238	ï 00EF 239
F-	ø 00F0 240	ñ 00F1 241	ò 00F2 242	ó 00F3 243	ô 00F4 244	õ 00F5 245	ö 00F6 246	÷ 00F7 247	ø 00F8 248	ù 00F9 249	ú 00FA 250	û 00FB 251	ü 00FC 252	ý 00FD 253	þ 00FE 254	ÿ 00FF 255

UNICODE

Unicode es un **estándar de codificación** de caracteres que asigna un número único (código) a cada símbolo utilizado en los sistemas de escritura **del mundo, independientemente** de la plataforma, el programa o el idioma.

En otras palabras, es un sistema que permite que **letras, números, símbolos y emojis** se representen de **forma universal** y consistente en computadoras y dispositivos.



Características de UNICODE

- **Universalidad:** incluye casi todos los **sistemas de escritura**: latín, árabe, chino, griego, cirílico, etc.
- **Compatibilidad con múltiples lenguajes y símbolos:** Soporta **letras**, **acentos**, **ideogramas**, **signos matemáticos**, **símbolos técnicos** y hasta **emojis**.
- **Código único por carácter:** cada carácter tiene un número asignado llamado **punto de código**.

	A	Æ	好	不
Punto de código	U+0041	U+05D0	U+597D	U+233B4
UTF-8	41	D7 90	E5 A5 BD	F0 A3 8E B4
UTF-16	00 41	05 D0	59 7D	D8 4C DF B4
UTF-32	00 00 00 41	00 00 05 D0	00 00 59 7D	00 02 33 B4

Formatos de codificación

Los **formatos de codificación** que se pueden usar con UNICODE se denominan **UTF-8, UTF-16 y UTF-32**.

- **UTF-8** utiliza **1 byte** para representar caracteres en el set **ASCII**, **2 bytes** para caracteres en **otros bloques** alfabéticos y **tres bytes** para **el resto** del BMP. Para los **caracteres complementarios** se utilizan **4 bytes**.
- **UTF-16:** utiliza **2 bytes** para **cualquier carácter** en el BMP y **4 bytes** para los **caracteres complementarios**.
- **UTF-32:** emplea **4 bytes** para **todos los caracteres**.